

- Classification Problem -

- Variable y that we want to predict is discrete valued.
- Bu problem için logistic regression algoritması kullanılır.

Exs: • Email: Spam / Not Spam • Online Transactions: Fraudulent (Yes/No)?
• Tumor: Malignant / Benign?


$$y \in \{0, 1\}$$

0: "Negative Class" (e.g. benign tumor)

1: "Positive Class" (e.g. malignant tumor)

→ Şimdilik y sadece 0 ve 1 olabilir, bu durumla ilgilenmiyoruz. ilerde Multiclass Classification Problems göreceğiz, $y \in \{0, 1, 2, 3\}$ olabilecek.

Binaryclass Classification ($y \in \{0, 1\}$)




→ Classification problem olmasına rağmen burada linear regression modelini kullanabiliriz.

→ Bir threshold belirleriz ve hypothesis $h_0(x) > 0.5$ ise $h_0(x) = 1$ deriz, kütüğe $h_0(x) = 0$ deriz.

$$h_0(x) = \theta^T \cdot x$$

Threshold classifier - output $h_0(x)$ at 0.5.
If $h_0(x) \geq 0.5$, predict "y=1"
If $h_0(x) < 0.5$, predict "y=0"

⊗ Bu örnek için, linear regression modeli işliyon ama biraz modifiye ederseniz acaba daha kullanışlı olacak mı?



→ Training set'e yeni eklenen data $h_0(x)$ 'i saptırdı ve aynı threshold için, hypothesis artık doğru sonuç vermiyor.

⊗ you linear regression model'i classification için kullanmak yerine ilk önce sigmoid fonksiyonuna eklerseniz

Classification $y = 0$ or 1

$h_{\theta}(x)$ can be > 1 or < 0 ... for Linear Regression model

→ Tahmin edilecek output 0 ve 1 olsa da, hypothesis sonuçları 0'dan büyük ve 1'den büyük olabilir bu anlamda.

→ ileriki bölümlerde Logistic Regression modeline gireceğiz.

Logistic Regression için $0 \leq h_{\theta}(x) \leq 1$

→ Ismin içinde regression olması kafa karıştırmıyor bu bir classification algorithm.

Logistic Regression

→ $0 \leq h_{\theta}(x) \leq 1$ istiyoruz.

→ Linear regression için $h_{\theta}(x) = \theta^T \cdot x$ idi.

→ Logistic Regression için $h_{\theta}(x) = g(\theta^T \cdot x)$

where

$$g(z) = \frac{1}{1 + e^{-z}}$$

z is real number


→ Sigmoid function

→ Logistic function

Synonyms

⊗ Thus

$$h_{\theta}(x) = g(\theta^T \cdot x) = \frac{1}{1 + e^{-\theta^T \cdot x}}$$



→ θ parametrelerini fit etmeyi daha sonra göreceğiz.

Ex: If $x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ \text{Tumor size} \end{bmatrix}$ and $h_{\theta}(x) = 0.7$

→ Tell patient that 70% chance of tumor being malignant.

→ Verilen tumor size için $y=1$ olma olasılığı 70%

→ $h_{\theta}(x) = p(y=1 | x; \theta)$ "probability that $y=1$ given x , parametrized by θ "

→ $p(y=0 | x; \theta) = 1 - p(y=1 | x; \theta) = 1 - 0.7 = 0.3$


Ekstra açıklama: Regression problem için, linear regression modelini kullandık ve bir $h_{\theta}(x)$ adadık. Daha sonra training set ile hypothesis ağırlık farkları minimize ettik burada cost function J 'i Gradient Descent algorithm ile veya analitik olarak minimize ederek yaptık. Sonuç olarak elde edilen $h_{\theta}(x)$ 'e verilen herhangi bir x bñe en gerçekçi output y 'yi verdi.

Classification için, Logistic Regression modeli kullanılarak hypothesis oluşturuldu $h_{\theta}(x)$ y 'ye cost function minimize edilerek en iyi $h_{\theta}(x)$ 'e ulaşıldı. Fakat burada $h_{\theta}(x)$ in sonucu $y=1$ olma olasılığını veriyor.

Logistic Regression

• $h_{\theta}(x) = g(\theta^T x) = p(y=1 | x; \theta)$

• $g(z) = \frac{1}{1 + e^{-z}}$



Suppose predict "y=1" if $h_{\theta}(x) \geq 0.5$

predict "y=0" if $h_{\theta}(x) < 0.5$

$g(z) \geq 0.5$ when $z \geq 0$

since

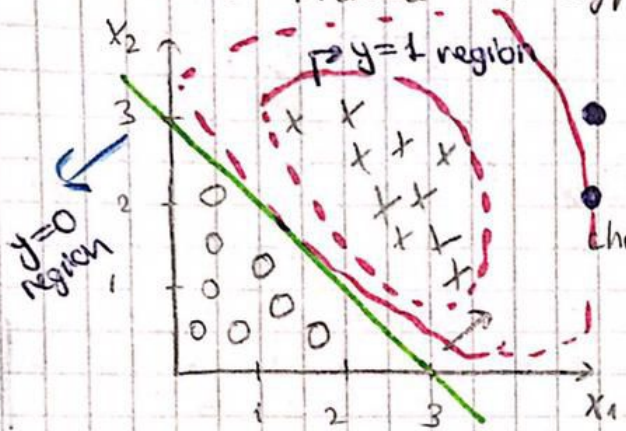
$h_{\theta}(x) = g(\theta^T x) \geq 0.5$ when $\theta^T x \geq 0$

→ olay şu $\theta^T x \geq 0$ için $g(\theta^T x) = h_{\theta}(x) \geq 0.5$ oluyor. Yani $y=1$ olma olasılığı ≥ 0.5 oluyor o zaman $y=1$ predictionı yapabiliriz

• $\theta^T x = 0$ bir ağırlık verin bu ağırlık bñe $h_{\theta}(x) = 0.5$ veren x ve θ değerlerini gösterin.

Verilen predict $y=1$ if $\theta^T x \geq 0$
predict $y=0$ if $\theta^T x < 0$

Ex: Let's suppose we have a training set as below and we have obtained an hypothesis as below:



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

Let's say by using an algorithm we chose: $\theta_0 = -3$ $\theta_1 = 1$ $\theta_2 = 1$

$$\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

→ Decision Boundary

→ Verilen hypothesis'i kullanarak, bu $h_{\theta}(x)$ 'in nerelerde $y=1$ nerelerde $y=0$ prediction'ı yaptığını bakalım!


★ Yada nerelerde $h_{\theta}(x) = 0.5$ olduğunu bakalım!

We know: Predict "y=1" if $\theta^T x \geq 0$

→ $x_1 + x_2 \geq 3$ için $h_{\theta}(x) \geq 0.5$ predict $y=1$.

★ Decision Boundary yalnızca $h_{\theta}(x)$ 'e bağlıdır, training set'e bağlı değil.

Ex: Non-Linear Decision Boundaries



Assume our hypothesis:

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

$$\text{Let's say } \theta = [-1 \ 0 \ 0 \ 1 \ 1]^T$$

Decision boundary'ı bulalım:

→ Predict $y=1$ when $-1 + x_1^2 + x_2^2 \geq 0 \Rightarrow x_1^2 + x_2^2 \geq 1$

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1^2 \cdot x_2 + \theta_5 x_1^2 \cdot x_2^2 + \theta_6 x_1^3 \cdot x_2 + \dots)$$

★ Farklı $h_{\theta}(x)$ 'ler için daha farklı ve complex Decision Boundaries elde edilebilir.

~ Logistic Regression - Cost Function ~

- Training Set: $\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$ m examples
- $x \in \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}$ • $x_0 = 1$ • $y \in \{0, 1\}$

• $h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$

Question: How to choose parameters θ ?


→ Linear Regression için: $J(\theta) = \frac{1}{m} \sum_{i=1}^m \left(\frac{1}{2} h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$

→ Let's say $\text{cost}(h_{\theta}(x^{(i)}), y^{(i)}) = \frac{1}{2} (h_{\theta}(x^{(i)}) - y^{(i)})^2$


→ $\text{cost}(h(x), y) = \frac{1}{2} (h_{\theta}(x) - y)^2$ (Simplified)

→ Logistic Regression için bu cost function'ı kullandıysak J non-convex bir form olur yani bir çok local optima olur.

→ Yani $h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$ 'i $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$ de yerine koyarsak J linear regression'da olduğu gibi convex olmasın diye olur.



→ Böyle bir $J(\theta)$ için gradient descent global minimum'ı bulamazdır.



⊛ $h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$ logistic function very nonlinear


olduğu için eski cost function tanımları non-convex oluyordu. Yeni bir cost function tanımlayarak $J(\theta)$ 'yi convex yaptık.

Logistic Regression Cost Function:



$$\text{cost}(h_\theta(x), y) = \begin{cases} -\log(h_\theta(x)) & \text{if } y=1 \\ -\log(1-h_\theta(x)) & \text{if } y=0 \end{cases}$$

If $y=1$



→ If hypothesis $h_\theta(x)$ predicts $y=1$ and indeed $y=1$ then $\text{cost} = 0$

→ $\text{Cost} = 0$ if $y=1, h_\theta(x)=1$

→ But as $h_\theta(x) \rightarrow 0$, $\text{cost} \rightarrow \infty$


• It means if $h_\theta(x)=0$ (predict $P(y=1|x;\theta)=0$), but $y=1$ we will penalize learning algorithm by a very large cost

→ Logistic regression için $h_\theta(x)$ 'in 0 ile 1 arasında olduğunu unutmamak için $h_\theta(x)$ aslında $y=1$ olma olasılığını veriyor.

→ Olay şu, cost 'u hesaplarken önceden y değeri farklı etmemek için y göre farklı alıyorduk. Şimdi $y=1$ ise farklı cost , $y=0$ ise farklı.

→ $y=1$ iken $h_\theta(x)$ bir 1 veriyorsa super çalışıyor bu $x(i)$ için cost 0! Fakat $y=1$ iken $h_\theta(x)=0$ veriyorsa, yani tümör malignan olduğunu vermemişse rağmen hipotez bunun olasılığı 0 diyorsa $\text{cost} \rightarrow \infty$ tamamen yanlış çalışıyor bu $h_\theta(x)$, θ 'ların değişmesi lazım.

If $y=0$



→ Demek ki'nin reverse'si, $h_\theta(x)=0$ diyorsa ve $y=0$ ise sıkıntı yok, $\text{cost}=0$

→ Fakat $y=0$ iken $h_\theta(x)=1$ verirse $\text{cost} \rightarrow \infty$, θ 'ların değişmesi şart.

Bu tek bir data line için yeni bir $x^{(i)}$ için ve bir $y = 0$ or $y = 1$ değeri için cost hesapları. $J(\theta)$ 'yi bulmak için tüm bunları toplam ve $\frac{1}{m}$ ile böler.

Simplified Cost Function and Gradient Descent

Cost Function for Logistic Regression

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Note: $y = 1$ or 0 Always

Simdi $y=0$ ve 1 için aynı cıvrı iki cost tanımlanmış yerine bunları birleştirilerek simplify edeceğiz:

$$\text{cost}(h_{\theta}(x), y) = -y \cdot (\log(h_{\theta}(x))) - (1-y) \log(1 - h_{\theta}(x))$$

Why this cost function? It can be derived from statistics using the principle of maximum likelihood estimation. And it is convex!

Thus

$$J(\theta) = \frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(h_{\theta}(x^{(i)})) + (1-y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

Bu fonksiyon logistic regression için convex olacaktır!

Cost function $J(\theta)$ yi yordak, artık amacımız bu $J(\theta)$ 'yi minimize edecek θ parametrelerini bulmak!

$$\rightarrow \min_{\theta} J(\theta) : \text{Get } \theta = \begin{bmatrix} \theta_0 \\ \vdots \\ \theta_n \end{bmatrix}$$

After obtaining θ , then we have $h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$ so we can make a prediction for given new $x^{(i)}$.

$$h_{\theta}(x) = P(y=1 | x; \theta) \text{ olduğunu unutma}$$

Cost function $J(\theta)$ 'yi minimize etmek için yare gradient descent kullanırız çünkü bu yare convex bir fonksiyon. Mantık aynı!

→ w3 3. videoda Advanced Optimization teknikleri
gösteriyor α 'yı seçmeden daha hızlı converge olan
complex method lar.

Gradient Descent

Want min $J(\theta)$: θ nasıl buluyoruz?

Repeat $\{$

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

Aynı

→ Simultaneously update all θ_j .

$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$

Önceki ile
birebir aynı!

$$\theta_j := \theta_j - \alpha \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$

Simultaneously update
all θ_j

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \text{ hepsi için simultaneously update}$$

* Same olarak gradient descent algorithm esnası
ile birebir aynı fakat $h_{\theta}(x)$ değişti!

* Önceden gradient descent'i moniter ederek converge
ettiğimizi görmekten bahsetmiştik aynı geçerli. $J(\theta)$ 'yi
iteration'a göre plot ederseniz hep azalması lazım.

$$\theta := \theta - \alpha \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] \cdot x^{(i)}$$

vektor formunda

* Feature scaling'ile logistic regression'da daha
hızlı bir convergence için kullanılır.

- Multiclass Classification -

$y=1$ $y=2$ $y=3$ $y=4$

Example: Email foldering/tagging: Work, Friends, Family, Hobby


* Şimdiye kadar binaryclass classification gördük $y=1$ ya da $y=0$ olmak zorundaydı. Burada $y=0, 1, 2, 3, \dots$ olabilir.

Example: Medical Diagnosis: Not ill, Cold, Flu


Example: Weather: Sunny, Cloudy, Rain, Snow

* y can take small number of discrete values. $y=0$ 'dan da başlayabilir, önemi yok.

Binary Classification



Multi-class classification



? How to get a learning algorithm?

→ Binary için, logistic regression modelini kullanırız ve belki bir çizgi çekeriz, decision boundary olarak. Bir tarafı positive class $y=1$, bir tarafı negatif class $y=0$ olur. Bu line'da $h(x) = 0.5$ i yeni 0.5 i temsil eder.

* "One vs All Classification" adında bir idea kullanarak, Eski model olarak multi-class classification için de çalışır hale getiririz.



* Nasıl Çalışır: Yukarıdaki gibi bir training set olsun.

Class 1: $\Delta \leftarrow y=1$


Class 2: $\square \leftarrow y=2$

Class 3: $\times \leftarrow y=3$

Yapılacak şey, training set'i alıp, 3 ayrı binary classification problemine dönüştürmek.



Önce Class 1'ı ele alalım class 1 vs all:



★ Class 1: positive class oldu, diğerleri negative class,

★ $h_{\theta}^{(1)}(x)$ assign edicet ve h_{θ} yaptığımız yapıcaz ve mesela selüldeli gibi bir decision boundary elde edeceğiz.

Sonra Class 2 için: Yeni bir logistic regression classifier $h_{\theta}^{(2)}(x)$ fit ederiz.

Sonra Class 3 için: $h_{\theta}^{(3)}(x)$

★ We have fit three classifiers for $i=1, 2, 3$,

$$h_{\theta}^{(i)}(x) = P(y=i | x; \theta) \quad (i=1, 2, 3)$$

Yani $h_{\theta}^{(1)}(x)$: verilen x dataseti için ve θ 'lar için $y=1$ olma olasılığını veriyor, diğerleri de aynı şekilde $y=2$ ve $y=3$ olma olasılığını veriyor.

One-vs-All: Train a logistic regression classifier $h_{\theta}^{(i)}(x)$ for each class i to predict the probability that $y=i$.

On a new input x , to make a prediction, pick the class p that maximizes

$$\max_p h_{\theta}^{(p)}(x)$$

Yani en yüksek olasılığı seçeriz.

w3 - Advanced Optimization Algorithms

→ Bunun kullanılarak logistic regression'in GDA ile çok daha hızlı çalışmasını ve large scale problemlere rahat uygulanabilirliğini sağlar.

→ GDA'nın dışında başka optimization algorithms de var:

- Conjugate gradient
- BFGS
- L-BFGS

- + No need to manually pick α
- + often faster than gradient descent
- More complex

Example:

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix}$$

$$J(\theta) = (\theta_1 - 5)^2 + (\theta_2 - 5)^2$$

$$\frac{\partial}{\partial \theta_1} J(\theta) = 2(\theta_1 - 5)$$

$$\frac{\partial}{\partial \theta_2} J(\theta) = 2(\theta_2 - 5)$$

Let's apply an advanced opt. algorithm to minimize $J(\theta)$:

function [JVal, gradient] = costFunction(theta)

$$JVal = (\text{theta}(1) - 5)^2 + (\text{theta}(2) - 5)^2;$$

$$\text{gradient} = \text{zeros}(2, 1);$$

$$\text{gradient}(1) = 2 * (\text{theta}(1) - 5);$$

$$\text{gradient}(2) = 2 * (\text{theta}(2) - 5);$$

NOW we can call adv. opt. function:
fminunc:

```
options = optimset('GradObj','on','MaxIter','400');
```

```
initialTheta = zeros(2, 1);
```

```
[optTheta, functionVal, exitFlag] = fminunc(@costFunction,  
initialTheta, options);
```

Önce üst taraftaki function'a end ekleyip costFunction ismi ile kaydet!
Sonra aşağıdaki kısmı başka mfile'ye yaz '400' yerine int isiyon
direkt 100 yaz. help fminunc da yardımcı olabilir.

Sonuçta Logistic Regression için:

$$\theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix} \begin{matrix} \theta_0(1) \\ \theta_0(2) \\ \vdots \\ \theta_0(n+1) \end{matrix}$$

```
function [JVal, gradient] = costFunction(theta)
```

```
JVal = [code to compute J(theta)]
```

```
gradient(1) = [code to compute  $\frac{\partial}{\partial \theta_0} J(\theta)$ ]
```

⋮

```
gradient(n+1) = [code to compute  $\frac{\partial}{\partial \theta_n} J(\theta)$ ]
```

Source fminunc'ı
kullandı ve
optimized theta
values will be
obtained.

**Ideal for large
scale (too many
features) problems**