


- NN Representations -

- Yeni learning algorithm modelimiz "Neural Networks" state of the art technique for many different machine learning problems.
- Why do we need another learning algorithm models than linear and logistic regression? Why do we need Neural Networks?
- Basitçe cevap şu: n large iken non-linear classifiers build etmek çok zor çünkü feature space will be too large bu da overfitting'e yol açabilir ve computationally expensive.

Ex: Supervised classification problem için bir training set olsun, aşağıdaki gibi:



- One thing we could do is, apply logistic regression with a lot of non-linear features like:

$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2 + \theta_4 x_1^2 x_2 + \theta_5 x_1^3 x_2 + \theta_6 x_1 x_2^2 + \dots)$$

- Yeterince polynomial kullanırsak belki kırmızı eğri gibi bir decision boundary elde edebiliriz.

- Logistic Regression yukarıdaki methodla çalışır ancak bunun için feature sayısının (x_1, x_2) a7 olması lazım. 2 feature için çalışır.

- Ancak bir çok machine learning problemi için 2'den çok daha fazla feature'imiz vardır.

- Mesela housing için evin satılma olasılığını bulmaya çalıştığımız bir classification problem olsun.

- $x_1 = \text{size}$, $x_2 = \# \text{ bedrooms}$, $x_3 = \# \text{ floors}$, ... $x_{100} = \dots$ gibi 100 tane feature olsun ($n=100$)

- $n=100$ için yukarıdaki gibi bir dağılımda kullanacağımız bir hipotez için tüm quadratic functions'ı dahil etsek:

$$\begin{array}{l} x_1^2, x_1 x_2, x_1 x_3, x_1 x_4, \dots, x_1 x_{100} \\ x_2^2, x_2 x_3, x_2 x_4, \dots, x_2 x_{100} \\ \vdots \\ x_{100}^2 \end{array}$$


$$\approx \frac{n^2}{2} \approx 5000 \text{ features!}$$

- Daha küçük bir feature space için ise yukarıdaki gibi bir data set ayrılamaz.

- Cibi e terimleri de alsak 170 000 term!

- W4 - IVX Representations -

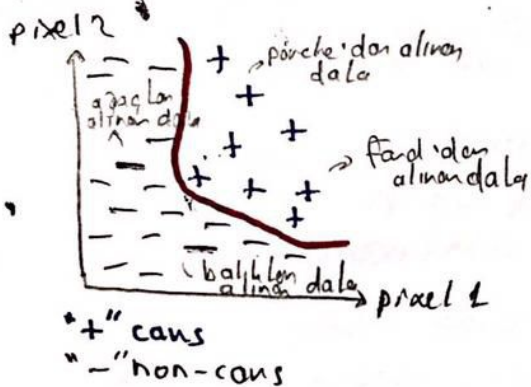
- For many machine learning problems n will be large! Let's consider the problem of computer vision.
- Suppose we wanna use machine learning to train a classifier to examine an image and tell us whether or not the image is car.



- Computer'in gördüğü pixel intensity values'dan oluşan bir matrix'len farklı değil. Her pixel'in brightness'ı yani pixel intensity'si farklıdır.

- Training set için farklı car pictures kullanılır. Training set learning algoritması beslenir ve bir classifier elde edilir.

→ Şimdi basitçe problemi açıklığa kavuşturmak için feature'ların $pixel 1$ ve $pixel 2$ adında 2 kritik pixel olduğunu kabul ediyorum.



- Her datanın bir araba veya araba-değil örneği şekli ettiğine dikkat et!

- Bu dağılımı ayırtabilmek için doğru eğriyi yaratacak bir non-linear hypothesis gerekir.

- 50×50 pixel images kullansak dahi $\rightarrow 2500$ pixel gibi bir initial feature size oluyor yani $n=2500$ bunu sadece linear lines için kullanabiliriz.

$$x = \begin{bmatrix} \text{pixel 1 intensity} \\ \text{pixel 2 intensity} \\ \vdots \\ \text{pixel 2500 intensity} \end{bmatrix} \quad \text{0-255 pixel intensity uclar}$$

- Tüm quadratic functions içeren bir nonlinear hypothesis kullanmak için ise $(x_i \times x_j) \approx \boxed{3 \text{ million features}}$

Neural Networks are much better way to learn complex nonlinear hypothesis even when n is large!

-WH - Neurons and the Brain -

- Origins of NUs: Algorithms that try to mimic the brain.
- Was widely used in 80s and 90s; popularity diminished in late 90s.
- Recently resurgence occurred: State-of-the-art technique for many applications.

-
- Beynimiz birca karmaşık fonksiyonu yerine getirmek için 1000lerce farklı programdan oluşmalı diye düşünebilirsiniz ama bu yanlış.
 - Bunun yerine beyin tek bir learning algorithm ile her işi öğreniyor.

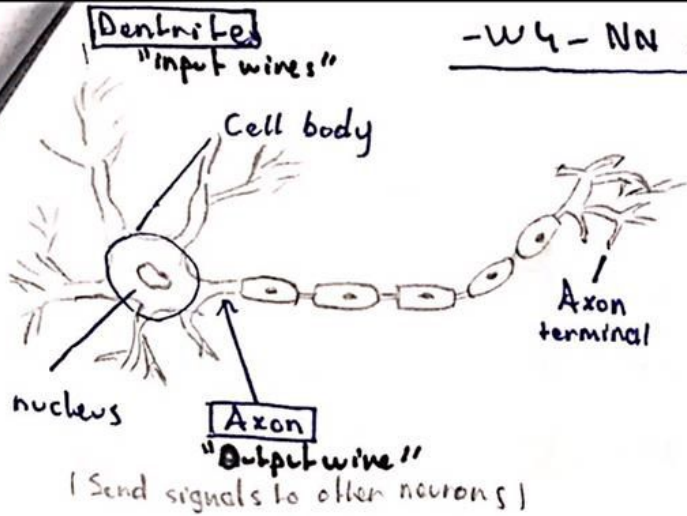
- Bazı konulardan bahsedebiliriz:

- Örneğin duyma işini yapan Auditory Cortex'e kulaktan giden bağlantı kesilip yerine görsel gelen data verilirse auditory cortex learns to see
- Somatosensory Cortex dokunma hissinin sağlar. Buna da re-wiring yapıp görsel veri sağlarsak görsel görmeyi öğrenir.

- Yani almost any sensor almost any part of brain'e bağlanınca brain figures it out how to deal with it. Bz de belki bu öğrenme algoritmasına yolunsayarak sonuç elde edebiliriz.

- Dil ile görme (Seeing with your tongue).
- Human echolocation (sonar).
- Haptic belt. Duvuhun sense.
- Implanting a 3rd eye.


-W4- NN Model Representations I-



• At a simplistic level, a neuron is a computational unit that gets a number of inputs through dendrites, does some computations then sends outputs via its axon to other neurons.

Artificial Neuron:

Neuron'u bir logistic unit olarak modelleye-



$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T \cdot x}} \text{ where } x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix}, \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix}$$


"weights" or "parameters"

• Bias unit, x_0 bazen 0'dir bazen 1'dir!

• This an artificial neuron with a

Sigmoid / Logistic Activation Function.

Neural Network:



- $a_i^{(j)}$: "activation" of unit i in layer j .
- $\Theta^{(j)}$: Matrix of weights controlling function/mapping from layer j to layer $j+1$.

Activation: The value that's computed and output by a specific unit or neuron.

$$a_1^{(2)} = g(\Theta_{10}^{(1)} \cdot x_0 + \Theta_{11}^{(1)} \cdot x_1 + \Theta_{12}^{(1)} \cdot x_2 + \Theta_{13}^{(1)} \cdot x_3)$$

$$a_2^{(2)} = g(\Theta_{20}^{(1)} \cdot x_0 + \Theta_{21}^{(1)} \cdot x_1 + \Theta_{22}^{(1)} \cdot x_2 + \Theta_{23}^{(1)} \cdot x_3)$$

$$a_3^{(2)} = g(\Theta_{30}^{(1)} \cdot x_0 + \Theta_{31}^{(1)} \cdot x_1 + \Theta_{32}^{(1)} \cdot x_2 + \Theta_{33}^{(1)} \cdot x_3)$$

$\Theta^{(1)} \in \mathbb{R}^{3 \times 4}$
Layer 1 ile Layer 2 baglan

$$h_{\theta}(x) = a_1^{(3)} = g(\Theta_{10}^{(2)} \cdot a_0^{(2)} + \Theta_{11}^{(2)} \cdot a_1^{(2)} + \Theta_{12}^{(2)} \cdot a_2^{(2)} + \Theta_{13}^{(2)} \cdot a_3^{(2)})$$

$\Theta^{(1)}$ size: $i+1$. layerdaki units (w/o bias) \times layerdaki units (w/o bias)

$\Theta^{(2)} \in \mathbb{R}^{4 \times 4}$
Layer 2 ile Layer 3 baglan


-w4 - NN Model Representations II-

Forward Propagation: Vectorised Implementation

$$a_1^{(2)} = g(\Theta_{10}^{(1)} \cdot x_0 + \Theta_{11}^{(1)} \cdot x_1 + \Theta_{12}^{(1)} \cdot x_2 + \Theta_{13}^{(1)} \cdot x_3)$$

$$a_2^{(2)} = g(\Theta_{20}^{(1)} \cdot x_0 + \Theta_{21}^{(1)} \cdot x_1 + \Theta_{22}^{(1)} \cdot x_2 + \Theta_{23}^{(1)} \cdot x_3)$$

$$a_3^{(2)} = g(\Theta_{30}^{(1)} \cdot x_0 + \Theta_{31}^{(1)} \cdot x_1 + \Theta_{32}^{(1)} \cdot x_2 + \Theta_{33}^{(1)} \cdot x_3)$$



$$h_0(x) = g(\Theta_{10}^{(2)} \cdot a_0^{(2)} + \Theta_{11}^{(2)} \cdot a_1^{(2)} + \Theta_{12}^{(2)} \cdot a_2^{(2)} + \Theta_{13}^{(2)} \cdot a_3^{(2)})$$

$$\bullet \quad x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix} \quad \bullet \quad z^{(2)} = \begin{bmatrix} z_1^{(2)} \\ z_2^{(2)} \\ z_3^{(2)} \end{bmatrix} = \begin{bmatrix} \Theta_{10}^{(1)} \cdot x_0 + \Theta_{11}^{(1)} \cdot x_1 + \Theta_{12}^{(1)} \cdot x_2 + \Theta_{13}^{(1)} \cdot x_3 \\ \Theta_{20}^{(1)} \cdot x_0 + \Theta_{21}^{(1)} \cdot x_1 + \Theta_{22}^{(1)} \cdot x_2 + \Theta_{23}^{(1)} \cdot x_3 \\ \Theta_{30}^{(1)} \cdot x_0 + \Theta_{31}^{(1)} \cdot x_1 + \Theta_{32}^{(1)} \cdot x_2 + \Theta_{33}^{(1)} \cdot x_3 \end{bmatrix}$$

$$\bullet \quad z^{(2)} = \Theta^{(1)} \cdot x = \Theta^{(1)} \cdot a^{(1)}$$

$$\bullet \quad a^{(2)} \in \mathbb{R}^3 = g(z^{(2)}) \in \mathbb{R}^3 \longrightarrow a^{(2)} = \begin{bmatrix} a_1^{(2)} \\ a_2^{(2)} \\ a_3^{(2)} \end{bmatrix} \quad \text{Bunu bulmuş olduk ama } h_0(x) \text{ için } a_0^{(2)} = 1 \text{ 'e de ihtiyac var!}$$

$$\bullet \quad \text{Add } a_0^{(2)} = 1 \text{ then } a^{(2)} \in \mathbb{R}^4 \rightarrow \text{Şimdi } h_0(x) \text{ 'i bulabiliriz.}$$

$$\bullet \quad h_0(x) = a^{(3)} = g(z^{(3)})$$

This is a relatively efficient way of computing $h(x)$

• This process of computing $h_0(x)$ is called "Forward Propagation".

What NN is doing and how they help us to learn complex nonlinear hypothesis.

• İlk layer'i düşünmeden gelinsek aslında sadece 1 logistic regression unit var, ve 4 input var yani 4 features: $(a_0^{(2)}, a_1^{(2)}, a_2^{(2)}, a_3^{(2)})$
Bu zaten yaptığımız bir şey.

$$h_0(x) = g(\Theta_{10}^{(2)} \cdot a_0^{(2)} + \Theta_{11}^{(2)} \cdot a_1^{(2)} + \Theta_{12}^{(2)} \cdot a_2^{(2)} + \Theta_{13}^{(2)} \cdot a_3^{(2)})$$

• NN works like logistic regression except rather than using the original features x_0, x_1, x_2, x_3 it uses this new features and these new features are learned as functions of inputs.


NNs: Examples and Intuitions

-W4-


How a NN can compute a complex non-linear function of the input?

Non-linear Classification Example: XOR/XNOR

- x_1, x_2 are binary (0 or 1)



Bu aslında sağdaki örneğin simplified hali!




Learning a non-linear decision boundary. Bu problem çözülebilir.

- Yukarıdaki örnek bir $y = x_1 \text{ XNOR } x_2$ örneği. 11 ve 00 için $y=1$
- Bize böyle bir training set verildi. NN ile öyle bir $h_\theta(x)$ elde edeceğiz ki, XNOR fonksiyonunun görevini yapsın!
- Bunu başarmak için daha basite ineceğiz önce "AND" ile başlayalım.


Simple Example: AND

- $x_1, x_2 \in \{0, 1\}$ (Binary Inputs)
- $y = x_1 \text{ AND } x_2$ (Target labels)



- $h_\theta(x) = g(\theta_{10}^{(1)} \cdot x_0 + \theta_{11}^{(1)} \cdot x_1 + \theta_{12}^{(1)} \cdot x_2)$ Formunda olduğunu biliyoruz şimdi parametrelere elle değer atayalım ve sırasıyla -30, 20, 20 olsun!

$$h_\theta(x) = g(-30 + 20x_1 + 20x_2)$$



x_1	x_2	$h_\theta(x)$
0	0	$g(-30) \approx 0$
0	1	$g(-10) \approx 0$
1	0	$g(-10) \approx 0$
1	1	$g(10) \approx 1$



$$\Rightarrow h_\theta(x) \approx x_1 \text{ AND } x_2$$

Example: OR



$$h_\theta(x) = g(-10 + 20x_1 + 20x_2)$$


x_1	x_2	$h_\theta(x)$
0	0	$g(-10) \approx 0$
0	1	$g(10) \approx 1$
1	0	$g(10) \approx 1$
1	1	$g(30) \approx 1$



-NNs: Examples and Intuitions-

-w4-





NOT Function or Negation:



x_1	$h_0(x)$
0	$g(10) \approx 1$
1	$g(-10) \approx 0$


• x_0 'ın başına "+" diğerlerinin başına large negative parameters!

Putting it Together: x_1 XNOR x_2 :



x_1	x_2	$a_1^{(2)}$	$a_2^{(2)}$	$h_0(x)$
0	0	0	1	1
0	1	0	0	0
1	0	0	0	0
1	1	1	0	1

• x_1 ve x_2 'yi kullanarak dataset'i tek bir line ile ayırmak imkansız ama $a_1^{(2)}$ ve $a_2^{(2)}$ featurelarını kullanarak tek bir line ile dataset'i ayırmak mümkün oluyor.



⊗ Eklenen her layer ile yeni bir eksen takımı yeni yeni features oluşturulmuş oluyor. Training set minimizasyonu.

⊗ Eklenen her neuron ise yeni bir line yani a_3 eklenseydi bir önceki layer eklense $(x_1 - x_2)$ 3 eğri seçmiş olacaktık, daha mantıklısı son layer'a eklenseydi a_1, a_2 'ye 2 eğri seçmiş olurduk.

NN style bir şey yapıyor, original feature ekseninde çok complex şekiller ile ayrılması gereken bir data set'i kendi yeni featurelarını yeni layerlar ile oluşturarak daha basitçe ayırıyor.